

Modelo de Trading Híbrido Predictivo-Decisional: Un Enfoque Basado en Cadenas de Markov y Aprendizaje Automático con Optimización Dinámica

Aplicación en Mercados de Alta Frecuencia

Autor: Juliot nuñez

Fecha: 10 de Noviembre de 2025

Resumen: Este paper presenta la arquitectura formal de un sistema de trading algorítmico diseñado para maximizar el valor esperado (EV) del retorno mediante la combinación de dos metodologías estadísticas avanzadas: Cadenas de Markov (CM) para la inercia histórica y Machine Learning (ML) para la corrección contextual en tiempo real. Se introduce el concepto de Continuación Óptima (CO) para mitigar el riesgo de overtrading y trampas de reversión post-evento, convirtiendo la paciencia en un parámetro optimizable.

1. Introducción y Fundamentos Metodológicos

El trading algorítmico moderno exige modelos que superen las limitaciones de los sistemas puramente reactivos (basados en indicadores) o puramente predictivos (basados en series de tiempo). El presente modelo aborda esta necesidad dividiendo el problema del trading en dos fases secuenciales y probabilísticas: una **Fase Predictiva** de alta fidelidad y una **Fase Decisional** basada en la teoría de la utilidad.

El estado del arte muestra que los modelos de CM son excelentes para capturar la *memoria* y la *inercia* de las transiciones de precios, pero fallan en incorporar el *contexto* dinámico (como la sobrecompra o el volumen inusual). Nuestro enfoque híbrido resuelve esta deficiencia al fusionar la probabilidad estática de Markov con el sesgo dinámico del ML.

1.1 El Conjunto de Estados Discretos (\$S\$)

La discretización del movimiento de precios es esencial. Se define un conjunto de siete estados, basados en la magnitud y dirección del cambio de precio (ΔP) en el marco temporal de la vela futura:

$S = \{P_3, P_2, P_1, N, B_1, B_2, B_3\}$

Estado	Descripción	ΔP (Umbral de Magnitud)	Color (Representación Visual)
P_3	Subida Fuerte (Strong Bullish)	$\Delta P \geq \tau_{++}$	Verde Oscuro
P_2	Subida Media (Medium Bullish)	$\tau_{+} \leq \Delta P < \tau_{++}$	Verde Medio
P_1	Subida Suave (Weak Bullish)	$0 < \Delta P < \tau_{+}$	Verde Claro
N	Neutral / Consolidación	$\Delta P = 0$ (o ΔP cercano a 0)	ΔP
B_1	Caída Suave (Weak Bearish)	$-\tau_{+} < \Delta P \leq 0$	Rojo Claro
B_2	Caída Media (Medium Bearish)	$-\tau_{++} < \Delta P \leq -\tau_{+}$	Rojo Medio
B_3	Caída Fuerte (Strong Bearish)	$\Delta P \leq -\tau_{++}$	Rojo Oscuro

2. FASE 1: Modelo Híbrido de Predicción (Markov-ML)

La tarea de la Fase 1 es generar el vector de probabilidad final $P(s' | S_t, \mathbf{F}_t)$ para el siguiente estado s' .

2.1 Esquema de Fusión de Expertos

El modelo de predicción opera como una **Función de Softmax Ponderada**, integrando dos "Expertos" independientes, cada uno aportando una vista sesgada de la realidad del mercado. Esta fusión garantiza que el modelo no se exceda ni en la dependencia histórica (overfitting a patrones pasados) ni en la reactividad contextual (ruido de indicadores de corto plazo).

Experto Q (Markov)	Experto PML (Contextual)
Fuente de Datos: Historial de Transiciones de Estado. Representa la distribución estocástica de largo plazo .	Fuente de Datos: Vector de Factores $\mathbf{F}_t$ (RSI, Volumen, Open Interest, Funding Rate, etc.). Representa la sensibilidad a las condiciones actuales .
Output $Q(s'$	$S_t)$: Probabilidad de Transición estática (Inercia). Es la probabilidad base.
Rol: Frena la reactividad excesiva al imponer la memoria histórica. Si el mercado rara vez salta de P_3 to B_3 , el valor $Q(B_3$	$P_3)$ será bajo, restringiendo la predicción del ML.

Fórmula de Ponderación Híbrida:

$$P(s'|S_t, \mathbf{F}_t) = \text{Softmax} \left(\log \left(Q(s' | S_t) \right) + \log \left(P_{\text{ML}}(s' | \mathbf{F}_t) \right) \right)$$

Nota: La implementación utiliza el producto directo $Q \cdot P_{\text{ML}}$ con normalización para simplificar el cálculo, siendo matemáticamente equivalente al logaritmo de las probabilidades combinadas. La normalización es crucial para asegurar que $\sum_{s' \in S} P(s'|...) = 1.0$ y que el vector de probabilidad resultante sea válido para el cálculo del Valor Esperado.

2.2 Proyección: Matriz de Transición de Markov (\$Q\$)

La matriz de transición Q es el núcleo de la memoria histórica. Su entrenamiento se lleva a cabo mediante el conteo de frecuencias absolutas de transiciones en un conjunto de datos extenso (ej. 50,000+ velas), garantizando una representación robusta del comportamiento estocástico del activo subyacente. Un ejemplo de la estructura de Q sería:

Q	P3	P2	P1	N	B1	B2	B3
P_3	0.45	0.25	0.15	0.05	0.05	0.03	0.02
N	0.05	0.10	0.20	0.30	0.20	0.10	0.05
B_3	0.01	0.02	0.05	0.10	0.25	0.35	0.22
(Suma de cada							

fila \$\sum = 1.0\$)							
-------------------------	--	--	--	--	--	--	--

Análisis de Proyección y la Propiedad de Markov: La fila \$N\$ (Neutral) presenta la mayor inercia a mantenerse en \$N\$ (0.30), lo cual refleja un patrón de consolidación común después de movimientos volátiles. Específicamente, después de una subida fuerte (\$P_3\$), la matriz sugiere que es más probable una continuación del impulso (0.45) o una desaceleración gradual (\$P_2\$, \$P_1\$) que una reversión inmediata a \$B_3\$ (0.02). La Matriz \$Q\$ opera bajo la propiedad de Markov, donde la probabilidad del estado futuro solo depende del estado actual. Esta inercia histórica es esencial para suavizar las predicciones del modelo ML, que, al ser sensible a los factores de corto plazo, puede ser vulnerable al ruido. La Matriz \$Q\$ asegura que las tendencias fundamentales y la inercia del activo guíen la predicción a menos que el contexto del ML sea abrumador.

3. FASE 2: Decisión Óptima y Continuación (Parada y Pausa)

La Fase 2 transforma el conocimiento probabilístico \$P(s'|...)\$ en una acción \$\pi \in \{\text{Abrir, Cerrar, Mantener, Pausa}\}\$.

3.1 Cálculo del Valor Esperado (EV)

El modelo de decisión se basa en la Teoría de la Decisión Bayesiana, eligiendo la política \$\pi\$ que maximice el \$EV\$ del retorno. El objetivo es calcular el *Payoff* promedio que se obtendría si la acción \$\pi\$ fuera repetida un número infinito de veces, considerando las probabilidades actuales del mercado.

$$EV(\pi) = \max_{\pi} \left(\sum_{s' \in S} P(s'|S_t, \mathbf{F}_t) \cdot R_{\pi}(s') \right)$$
Donde \$R_{\pi}(s')\$ es la recompensa (ganancia o pérdida) asociada a la política \$\pi\$ si ocurre el estado \$s'\$.

3.1.1 Ejemplo de Proyección de Payoff (\$R_{\pi}\$)

La matriz de recompensas \$R_{\pi}\$ es altamente asimétrica, reflejando la configuración de Stop Loss (SL) y Take Profit (TP) de la estrategia. La asimetría está intencionadamente diseñada para favorecer escenarios donde la ganancia esperada (\$R_{\text{Ganancia}}\$) es significativamente mayor que la pérdida esperada (\$R_{\text{Pérdida}}\$), manteniendo un ratio riesgo-recompensa favorable.

Recompensa RLong (Abrir Long)	P3	P2	P1	N	B1	B2	B3
Payoff (\$R_{\text{Long}}\$)	\$+3.0R\$	\$+2.0R\$	\$+1.0R\$	\$0\$	\$-0.5R\$	\$-1.0R\$	\$-2.0R\$

Proyección de Retorno: Si \$R\$ es la unidad de riesgo, una política 'Abrir Long' tiene un \$EV\$ de:

$EV(\text{Long}) = P(P_3) \cdot (3.0R) + P(P_2) \cdot (2.0R) + \dots + P(B_3) \cdot (-2.0R)$
El sistema solo ejecuta 'Abrir Long' si $EV(\text{Long}) > EV(\text{Mantener})$ y $EV(\text{Long}) > \text{Umbral de Confianza}$. Este Umbral de Confianza actúa como un segundo filtro, asegurando que la operación solo se inicie si el retorno esperado supera un nivel mínimo de rentabilidad predefinido.

3.2 Principio de Continuación Óptima (CO)

Este principio aborda la debilidad de los modelos reactivos identificada en la experimentación: la tendencia a reabrir posiciones inmediatamente después de un evento de salida (TP o SL), a menudo coincidiendo con la reversión de la volatilidad o un período de baja probabilidad de continuación. La **Continuación Óptima** formaliza la *paciencia estratégica* al imponer un **periodo de enfriamiento (Cooldown)**.

El CO impone una **Penalidad de Pausa** (\$\text{Penalidad}_{\text{CO}}\$) al \$EV\$ de cualquier acción de apertura (\$\pi_{\text{Abrir}}\$) si un COOLDOWN_TIMER está activo, garantizando que el sistema descanse después de un evento de alta energía.

3.2.1 Proyección y Calibración del CO

Evento de Salida	COOLDOWN_TIMER (Velas)	PenalidadCO (en R)	Justificación
Take Profit (TP)	5 velas	\$-2.0R\$	El mercado está "agotado" después de un movimiento exitoso. La alta penalización

			disuade la reapertura inmediata que podría caer en una trampa de reversión.
Stop Loss (SL)	3 velas	\$-1.5R\$	Necesidad de reevaluar las condiciones tras un error de predicción. El período más corto permite una rápida reincorporación si el sesgo del ML se corrige, pero la penalidad evita la impulsividad.

Fórmula del EV Ajustado por CO:

$$EV(\pi_{\text{Abrir}})_{\text{CO}} = EV(\pi_{\text{Abrir}}) - I_{\text{CO}} \cdot \text{Penalidad}_{\text{CO}}$$

Donde I_{CO} es una función indicadora (1 si COOLDOWN_TIMER > 0, 0 en caso contrario).

Implicación de la Proyección: El impacto de esta penalidad es que, durante el período de enfriamiento, el \$EV\$ de las acciones de apertura se reduce drásticamente. Esto obliga al sistema a elegir $\pi = \text{Mantener Posición}$ (donde el \$EV\$ es neutro, cercano a \$0\$) a menos que la predicción híbrida (Fase 1) genere una probabilidad de éxito *extraordinariamente alta* que compense la penalidad. De esta forma, el modelo sólo rompe la pausa si existe una señal de alta convicción que justifique ignorar el riesgo de reversión post-evento.

4. Diagrama de Flujo del Proceso Decisional Híbrido

A continuación, se presenta el diagrama de flujo que resume la interacción entre las dos fases y el Filtro de Continuación Óptima.

graph TD

A[Inicio: Nueva Vela Cerrada] --> B[Capturar S_t y Vector de Factores $\mathbf{F}_t$];

subgraph Fase 1: Predicción Híbrida

B --> C[Experto Q (Markov): Obtener $Q(s|S_t)$];

B --> D[Experto ML (Contextual): Obtener $P_{ML}(s|\mathbf{F}_t)$];

C & D --> E[Fusión y Normalización: Calcular $P(s|S_t, \mathbf{F}_t)$];

end

E --> F[Fase 2: Evaluar Políticas π];

subgraph Fase 2: Optimización y Pausa

F --> G[Calcular EV(π) para todas las π];

G --> H{¿COOLDOWN_TIMER > 0?};

H -- Sí --> I[Aplicar Penalidad_CO a EV(π_{Abrir})];

H -- No --> J[EV sin Penalidad];

I --> K[Seleccionar $\pi_{\text{opt}} = \arg\max(EV)$];

J --> K;

end

K --> L{¿ $EV(\pi_{\text{opt}}) > \text{Umbral de Confianza?}$ };

L -- Sí --> M[Ejecutar π_{opt} (Abrir/Cerrar/Pausa)];

L -- No --> N[Decisión Final: Mantener Posición];

M --> O{¿Operación Cerrada?};

O -- Sí --> P[Actualizar LAST_OUTCOME y Reiniciar COOLDOWN_TIMER];

O -- No --> A;

P --> A;

N --> A;

4.1 Proyección Gráfica: Convergencia de Probabilidades

La robustez del modelo reside en la convergencia y divergencia controlada de las probabilidades generadas por los dos expertos, Q y P_{ML} .

- **Escenario 1 (Acuerdo - Alta Confianza):** Si $Q(P_3)$ es alto y $P_{ML}(P_3)$ es alto, la probabilidad final $P(P_3)$ converge rápidamente a un valor muy alto (ej., 95%). En este escenario, la historia y el contexto están alineados, y el sistema opera con la máxima confianza, lo que justifica incluso romper un periodo de pausa forzada (CO).

- **Escenario 2 (Conflicto - Advertencia):** Si $Q(\text{P3})$ es alto (inercia alcista), pero $P_{\text{ML}}(\text{P3})$ es bajo (debido a que el RSI está en 90, el volumen disminuye y el Open Interest muestra fuerte toma de ganancias), la probabilidad final $P(\text{P3})$ será moderada (ej., 60–70%). Esta divergencia es una señal de advertencia que el modelo de Parada Óptima (Fase 2) interpreta como menor confianza, lo que reduce el EV de la acción y promueve la decisión de **Mantener Posición** o, si el timer está activo, la **PAUSA ESTRATÉGICA** a pesar de la tendencia histórica.

5. Conclusiones y Futuras Direcciones

El modelo Híbrido Markov-ML con Optimización Dinámica representa un avance significativo al integrar la memoria estocástica con el contexto de aprendizaje profundo. Esta sinergia reduce la varianza de la predicción y aumenta la fidelidad del EV calculado.

La adición del principio de Continuación Óptima (CO) es, desde una perspectiva de gestión de riesgo, vital para la supervivencia a largo plazo en mercados volátiles. Al penalizar matemáticamente la impulsividad, el modelo mitiga la exposición innecesaria post-evento, preservando el capital en los momentos de mayor incertidumbre (consolidación o reversión), y asegurando que la paciencia sea un parámetro de optimización matemática que contribuye directamente a la maximización del *Sharpe Ratio*.

Las futuras direcciones incluyen la optimización *in-vivo* de los umbrales de discretización (τ), la auto-calibración de la $\text{Penalidad}_{\text{CO}}$ basada en el *drawdown* histórico y la volatilidad, y la expansión de la Matriz Q para incorporar Cadenas de Markov Ocultas (HMM) en la Fase 1, lo que permitiría inferir un "estado oculto" del mercado (ej., acumulación o distribución) que no es directamente observable en el precio.